UTS

PEMBELAJARAN MESIN

NAMA : Claudia Sherly Febriana Dewi

NIM : 202431160

KELAS : F

DOSEN : Dr. Dra. Dwina Kuswardani, M.Kom

NO.PC : 16

ASISTEN : 1. Jonathan Juan Setyanto

2. Muhammad Caisar Gemilang Pratama

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2026/2027

DAFTAR ISI

BAB I 3
PENDAHULUAN 3
1.1 Rumusan Masalah 3
1.2 Tujuan Masalah 3
1.3 Manfaat Masalah 3
BAB II 4
LANDASAN TEORI 4
2.1 Pembelajaran Mesin 4
2.2 Dataset Diabetes 4
2.3 Exploratory Data Analysis (EDA) 4
2.4 Preprocessing Data 4
2.5 K-Nearest Neighbors (KNN) 4
2.6 Linear Regression 5
2.7 Evaluasi Model 5
2.8 Ketidakseimbangan Kelas pada Dataset Diabetes 5
2.9 Standardisasi Fitur dan Pengkodean Data 5
2.10 Prinsip Kerja dan Parameter K-Nearest Neighbors 6
2.1 Linear Regression untuk Target Biner 6
BAB III 8
HASIL 8
3.1 Penjelasan Cell Code 8
3.2 Hasil EDA 10
3.3 Hasil Model KNN 10
3.4 Hasil Linear Regression 11
3.5 Perbandingan dan Analisis 11
3.6 Interpretasi Hasil Confusion Matrix 11
3.9 Perbandingan Metrik Evaluasi 12
BAB IV 14
PENUTUP 14
4.1 Kesimpulan Teori 14
4.2 Kesimpulan Praktikum 14
DAFTAR PUSTAKA 15

BAB I

PENDAHULUAN

1.1 Rumusan Masalah

Dataset diabetes memuat atribut demografis dan kesehatan yang dapat digunakan untuk mempelajari pola label diabetes. Permasalahan praktikum ini adalah bagaimana melakukan eksplorasi dan preprocessing dataset, membangun model K-Nearest Neighbors (KNN) dan Linear Regression sesuai pembagian UTS, serta mengevaluasi dan membandingkan hasil prediksinya. Distribusi label tidak seimbang, sehingga akurasi perlu dibaca bersama metrik lain

1.2 Tujuan Masalah

Tujuan praktikum adalah memahami karakteristik dataset diabetes, melakukan EDA dan preprocessing, melatih model KNN dan Linear Regression, mengukur performa pada data uji, serta menjelaskan kelebihan dan keterbatasan hasil berdasarkan metrik evaluasi.

1.3 Manfaat Masalah

Praktikum memberikan pengalaman menerapkan alur kerja pembelajaran mesin dari pemahaman data hingga evaluasi model. Perbandingan metrik juga menunjukkan pentingnya menilai recall dan F1-score, khususnya ketika kelas positif lebih sedikit daripada kelas negatif. Hasil ini bersifat akademik dan bukan alat diagnosis medis.

BAB II
LANDASAN TEORI

2.1 Pembelajaran Mesin

Pembelajaran mesin merupakan pendekatan komputasi yang mempelajari pola dari data untuk menghasilkan prediksi atau keputusan. Dalam supervised learning, model dilatih menggunakan pasangan fitur dan label yang sudah diketahui. Kualitas evaluasi bergantung pada pemisahan data latih dan data uji serta pemilihan metrik yang sesuai dengan tujuan

2.2 Dataset Diabetes

Dataset yang digunakan adalah file 02_diabetes.csv dari paket Dataset_UTS_2026. Dataset memiliki 100.000 baris dan 9 kolom: gender, age, hypertension, heart_disease, smoking_history, bmi, HbA1c_level, blood_glucose_level, dan diabetes. Kolom diabetes menjadi target biner: 0 berarti tidak diabetes dan 1 berarti diabetes. Pada data ini, kelas 0 berjumlah 91.500 (91,5%) dan kelas 1 berjumlah 8.500 (8,5%). Atribut gender dan smoking_history bersifat kategorikal, sedangkan atribut lainnya merupakan numerik. Tidak ditemukan nilai kosong. Pemeriksaan menemukan 3.854 baris duplikat; dalam eksperimen ini data dipertahankan sesuai file sumber, sehingga duplikasi menjadi salah satu keterbatasan yang perlu dicatat.

2.3 Exploratory Data Analysis (EDA)

DA dilakukan untuk memahami ukuran data, tipe atribut, nilai kosong, duplikasi, statistik deskriptif, dan distribusi target. Distribusi kelas penting karena model dapat memperoleh akurasi tinggi dengan memprediksi kelas mayoritas, tetapi tetap melewatkan banyak kasus pada kelas minoritas. Karena itu, hasil perlu dianalisis menggunakan balanced accuracy, precision, recall, F1-score, dan ROC-AUC selain accuracy

2.4 Preprocessing Data

Data dipisahkan menjadi fitur (X) dan target (y). Fitur kategorikal dikonversi menggunakan one-hot encoding agar dapat diproses model numerik. Fitur numerik distandardisasi dengan StandardScaler agar skala antarf fitur tidak mendominasi perhitungan jarak, terutama pada KNN. Preprocessing ditempatkan di dalam pipeline dan dipelajari dari data latih untuk menghindari kebocoran informasi dari data uji. Pembagian data adalah 80% latih dan 20% uji, dengan stratify agar proporsi kelas tetap terjaga

2.5 K-Nearest Neighbors (KNN)

KNN merupakan metode berbasis kedekatan yang menentukan kelas sampel baru berdasarkan label dari sejumlah tetangga terdekat. Pada eksperimen ini digunakan k=5 dan bobot distance, sehingga tetangga yang lebih dekat memberikan pengaruh lebih besar. KNN tidak membangun bentuk fungsi global, tetapi prediksinya dipengaruhi pemilihan k, metrik jarak, skala fitur, dan distribusi kelas. Penelitian Azzahrah dan Alamsyah (2023) membandingkan KNN dengan metode klasifikasi lain untuk data diabetes dan melaporkan bahwa preprocessing serta validasi silang merupakan bagian penting dari eksperimen. Penelitian lain juga mengkaji metode nearest-neighbor untuk deteksi diabetes (Suyanto et al., 2022)

2.6 Linear Regression

Linear regression memodelkan hubungan antara fitur dan target numerik dengan mengestimasi kombinasi linear yang meminimalkan jumlah kuadrat galat. Pada tugas ini target diabetes bernilai 0 atau 1, sehingga Linear Regression bukan algoritma klasifikasi standar dan prediksinya dapat berada di luar rentang probabilitas. Untuk memenuhi pembagian algoritma, nilai prediksi dikonversi menjadi label dengan ambang 0,5. Oleh sebab itu, hasilnya diperlakukan sebagai pembanding eksperimental dengan keterbatasan metodologis, bukan model diagnosis yang direkomendasikan.

2.7 Evaluasi Model

Accuracy mengukur proporsi seluruh prediksi yang benar. Precision mengukur proporsi prediksi positif yang benar, sedangkan recall mengukur proporsi kasus positif aktual yang berhasil ditemukan. F1-score merupakan rata-rata harmonik precision dan recall. Balanced accuracy menghitung rata-rata recall tiap kelas, sehingga lebih informatif ketika kelas tidak seimbang. ROC-AUC menilai kemampuan pemeringkatan skor model pada berbagai ambang. Untuk Linear Regression, RMSE mengukur

2.8 Ketidakseimbangan Kelas pada Dataset Diabetes

Ketidakseimbangan Kelas pada Dataset Diabetes Ketidakseimbangan kelas terjadi ketika jumlah observasi pada satu kelas jauh lebih banyak dibandingkan kelas lainnya. Pada dataset praktikum ini, label tidak diabetes (0) mendominasi sekitar 91,5% data, sedangkan label diabetes (1) sekitar 8,5%. Komposisi tersebut perlu diperhatikan karena model yang selalu menebak kelas mayoritas pun dapat menghasilkan akurasi yang tampak tinggi, meskipun tidak mampu mengenali sebagian besar kasus diabetes. Oleh sebab itu, akurasi tidak cukup digunakan sebagai satu-satunya ukuran keberhasilan model.

Dalam konteks klasifikasi kesehatan, kesalahan prediksi dibedakan menjadi false positive dan false negative. False positive berarti model memprediksi kelas diabetes padahal label sebenarnya bukan diabetes. False negative berarti model gagal mengenali observasi yang sebenarnya berlabel diabetes. Keduanya memiliki konsekuensi berbeda, sehingga evaluasi perlu melihat confusion matrix serta metrik precision dan recall. Recall menunjukkan seberapa banyak kasus positif yang berhasil ditemukan, sedangkan precision menjelaskan seberapa tepat prediksi positif yang diberikan. Penanganan ketidakseimbangan dapat dilakukan dengan pembagian data berstratifikasi, pemberian bobot kelas, undersampling kelas mayoritas, atau oversampling kelas minoritas. Teknik sampling tidak boleh diterapkan sembarangan; sampling hanya dilakukan pada data latih agar informasi dari data uji tidak bocor ke proses pelatihan. Pada praktikum ini, pembagian data dilakukan dengan stratifikasi untuk mempertahankan proporsi kelas pada data latih dan data uji. Ketidakseimbangan tetap dipertimbangkan ketika hasil evaluasi ditafsirkan. Olisah et al. (2022) dan tinjauan preprocessing diabetes tahun 2024 menegaskan bahwa karakteristik data serta pilihan preprocessing berpengaruh terhadap hasil model.

2.9 Standardisasi Fitur dan Pengkodean Data

Model pembelajaran mesin umumnya memerlukan data dengan format yang sesuai dengan perhitungan algoritmanya. Dataset diabetes berisi fitur numerik, seperti usia, BMI, dan kadar HbA1c, serta fitur kategorikal, seperti gender dan smoking_history. Fitur kategorikal perlu diubah ke bentuk numerik agar dapat digunakan oleh algoritma. Salah satu pendekatan yang

umum digunakan adalah one-hot encoding, yaitu membuat kolom indikator untuk kategori yang tersedia. Cara ini menghindari pemberian urutan angka yang seolah-olah menunjukkan tingkatan pada kategori yang sebenarnya tidak memiliki urutan.

Standardisasi penting terutama bagi algoritma yang menggunakan jarak. StandardScaler mengubah nilai fitur numerik berdasarkan rata-rata dan simpangan baku pada data pelatihan sehingga fitur berada pada skala yang lebih sebanding. Tanpa standardisasi, fitur dengan rentang angka besar dapat mendominasi perhitungan jarak, meskipun rentang tersebut tidak berarti lebih penting. Parameter standardisasi harus dipelajari hanya dari data latih, kemudian diterapkan pada data uji. Praktik ini mengurangi risiko kebocoran data dan membuat evaluasi lebih dapat dipercaya. Pengkodean dan standardisasi sebaiknya dijalankan melalui pipeline preprocessing. Pipeline menggabungkan langkah pengolahan data dengan model sehingga urutan transformasi konsisten pada saat pelatihan dan prediksi. Untuk data campuran, ColumnTransformer dapat menerapkan one-hot encoding pada kolom kategorikal dan standardisasi pada kolom numerik. Sida Nanda dan Suputra (2024) pada klasifikasi diabetes juga menerapkan data cleaning, encoding, analisis distribusi, dan normalisasi sebelum model dilatih. Temuan tersebut mendukung bahwa preprocessing merupakan bagian penting dari eksperimen, bukan sekadar langkah teknis tambahan.

2.10 Prinsip Kerja dan Parameter K-Nearest Neighbors

K-Nearest Neighbors (KNN) merupakan algoritma supervised learning yang menentukan label suatu observasi berdasarkan kedekatannya dengan sejumlah observasi pada data latih. Untuk sebuah data baru, algoritma menghitung jarak terhadap data latih, memilih sebanyak k tetangga terdekat, lalu menentukan kelas berdasarkan suara mayoritas atau pembobotan tetangga. Pada praktikum ini digunakan k=5 dan pembobotan distance, sehingga tetangga yang lebih dekat dapat memberikan pengaruh lebih besar terhadap keputusan klasifikasi.

Pemilihan nilai k memengaruhi kompleksitas keputusan model. Nilai k yang sangat kecil dapat membuat prediksi sensitif terhadap noise atau satu observasi tertentu. Sebaliknya, nilai k yang terlalu besar dapat membuat batas keputusan terlalu umum dan mengabaikan pola lokal. Karena KNN bergantung pada jarak, skala fitur, pengkodean kategori, dan pilihan metrik jarak dapat memengaruhi hasil. KNN umumnya membutuhkan preprocessing yang konsisten dan sebaiknya diuji dengan beberapa nilai k melalui validasi silang apabila ruang lingkup praktikum memungkinkan.

KNN memiliki kelebihan berupa konsep yang relatif mudah dipahami dan tidak membutuhkan proses pembentukan parameter model yang rumit. Namun, kebutuhan komputasinya dapat meningkat ketika jumlah data latih membesar karena jarak ke banyak observasi perlu dihitung saat prediksi. KNN juga dapat terpengaruh oleh fitur yang tidak relevan dan distribusi kelas yang tidak seimbang. Penelitian Musa et al. (2024) serta Sida Nanda dan Suputra (2024) memperlihatkan penggunaan KNN pada klasifikasi diabetes dan menekankan evaluasi dengan metrik lebih dari sekadar accuracy. Hasil KNN pada praktikum perlu dibaca bersama precision, recall, F1-score, dan confusion matrix.

2.1 Linear Regression untuk Target Biner

Linear Regression adalah metode regresi yang memodelkan hubungan antara variabel target numerik dan sekumpulan fitur melalui kombinasi linear. Model memperkirakan koefisien yang meminimalkan jumlah kuadrat selisih antara nilai aktual dan nilai prediksi. Secara umum, metode ini digunakan untuk target kontinu. Pada praktikum ini, target diabetes

memiliki dua nilai, yaitu 0 dan 1. Linear Regression tetap dijalankan sesuai pembagian algoritma UTS, kemudian skor prediksinya diubah menjadi kelas menggunakan ambang 0,5 agar dapat dibandingkan dengan metrik klasifikasi. Penggunaan Linear Regression pada target biner perlu dipahami sebagai pendekatan pembanding, bukan pilihan utama untuk klasifikasi. Nilai prediksi regresi tidak dibatasi pada rentang 0 sampai 1, sehingga interpretasinya berbeda dari probabilitas klasifikasi. Mengubah skor menjadi kelas menggunakan ambang 0,5 juga memengaruhi jumlah prediksi positif dan negatif. Ambang yang lebih rendah biasanya meningkatkan jumlah prediksi positif dan berpotensi meningkatkan recall, tetapi dapat menurunkan precision. Karena itu, hasil klasifikasi dari Linear Regression harus dijelaskan dengan menyebutkan ambang yang digunakan serta keterbatasan metodenya.

BAB III

HASIL

3.1 Penjelasan Cell Code

- Import Library

Import Library

```
In [1]:
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.pipeline import Pipeline
from sklearn.neighbors import KNeighborsClassifier
from sklearn.linear_model import LinearRegression
from sklearn.metrics import (
    accuracy_score, balanced_accuracy_score, precision_score, recall_score,
    f1_score, confusion_matrix, classification_report, roc_auc_score,
    mean_squared_error, r2_score, ConfusionMatrixDisplay
)
pd.set_option('display.max_columns', None)

RANDOM_STATE = 42
```

Memuat library untuk pengolahan tabel, visualisasi, preprocessing, pembagian dataset, pemodelan, dan evaluasi. Random state ditetapkan agar pembagian data dapat direproduksi

- Memuat Dataset

Dataset

```
In [3]:
#202431160_CLAUDIA
df = pd.read_csv('02_diabetes.csv')
print('Ukuran dataset:', df.shape)
display(df.head())
display(df.info())
```

```
Ukuran dataset: (100000, 9)
```

	gender	age	hypertension	heart_disease	smoking_history	bmi	HbA1c_level	blood_glucose_level	diabetes
0	Female	80.0	0	1	never	25.19	6.6	140	0
1	Female	54.0	0	0	No Info	27.32	6.6	80	0
2	Male	28.0	0	0	never	27.32	5.7	158	0
3	Female	36.0	0	0	current	23.45	5.0	155	0
4	Male	76.0	1	1	current	20.14	4.8	155	0

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 100000 entries, 0 to 99999
Data columns (total 9 columns):
 #   Column               Non-Null Count   Dtype
---  ------               --------------   -----
 0   gender               100000 non-null  object
 1   age                  100000 non-null  float64
 2   hypertension         100000 non-null  int64
 3   heart_disease        100000 non-null  int64
 4   smoking_history      100000 non-null  object
 5   bmi                  100000 non-null  float64
 6   HbA1c_level          100000 non-null  float64
 7   blood_glucose_level  100000 non-null  int64
 8   diabetes             100000 non-null  int64
dtypes: float64(3), int64(4), object(2)
memory usage: 6.9+ MB

None
```

Membaca 02_diabetes.csv dan menampilkan ukuran serta beberapa baris pertama untuk memastikan file terbaca.

- EDA

EDA

```
In [4]:
#202431160_CLAUDIA
print('Tipe data:')
display(df.dtypes.to_frame('Tipe Data'))
print('Jumlah missing value per kolom:')
display(df.isna().sum().to_frame('Missing Value'))
print('Jumlah duplikasi:', df.duplicated().sum())
print('Distribusi target diabetes:')
display(df['diabetes'].value_counts().rename(index={0:'Tidak diabetes', 1:'Diabetes'}).to_frame('Jumlah'))
display(df.describe(include='all').T)
```

Memeriksa tipe data, missing value, duplikasi, distribusi target, dan statistik deskriptif untuk memahami kualitas data

- Visualisasi EDA

In [5]:
```
#202431160_CLAUDIA
fig, axes = plt.subplots(1, 2, figsize=(12, 4))
counts = df['diabetes'].value_counts().sort_index()
axes[0].bar(['Tidak diabetes', 'Diabetes'], counts.values)
axes[0].set_title('Distribusi Target Diabetes')
axes[0].set_ylabel('Jumlah')
axes[1].hist(df.loc[df['diabetes'] == 0, 'age'], bins=25, alpha=0.6, label='Tidak diabetes')
axes[1].hist(df.loc[df['diabetes'] == 1, 'age'], bins=25, alpha=0.6, label='Diabetes')
axes[1].set_title('Distribusi Usia berdasarkan Target')
axes[1].legend()
plt.tight_layout()
plt.show()
```

Membuat grafik distribusi label diabetes dan distribusi usia berdasarkan label untuk melihat ketidakseimbangan target dan gambaran atribut

- Preprocessing

Preprocessing

In [6]:
```
#202431160_CLAUDIA
# Target dipisahkan dari fitur.
X = df.drop(columns='diabetes')
y = df['diabetes']

categorical_features = X.select_dtypes(include=['object']).columns.tolist()
numerical_features = X.select_dtypes(exclude=['object']).columns.tolist()

preprocessor = ColumnTransformer(
    transformers=[
        ('numerik', StandardScaler(), numerical_features),
        ('kategori', OneHotEncoder(handle_unknown='ignore'), categorical_features)
    ]
)

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=RANDOM_STATE, stratify=y
)
print('Fitur numerik:', numerical_features)
print('Fitur kategorikal:', categorical_features)
print('Ukuran X_train:', X_train.shape, '| X_test:', X_test.shape)
print('Proporsi target pada data penuh:')
display(y.value_counts(normalize=True).rename('Proporsi').to_frame())
```

Memisahkan fitur dan target, mengenali kolom kategorikal/numerik, membuat one hot encoding dan standardisasi, lalu membagi data 80:20 dengan stratifikasi

- Fungsi Evaluasi

Fungsi Evaluasi

In [8]:
```
#202431160_CLAUDIA
def evaluate_classifier(name, y_true, y_pred, scores=None):
    result = {
        'Algoritma': name,
        'Accuracy': accuracy_score(y_true, y_pred),
        'Balanced Accuracy': balanced_accuracy_score(y_true, y_pred),
        'Precision': precision_score(y_true, y_pred, zero_division=0),
        'Recall': recall_score(y_true, y_pred, zero_division=0),
        'F1-score': f1_score(y_true, y_pred, zero_division=0)
    }
    if scores is not None:
        result['ROC-AUC'] = roc_auc_score(y_true, scores)
    return result
```

Menghitung accuracy, balanced accuracy, precision, recall, F1-score, dan ROC AUC agar performa model dapat dibandingkan secara konsisten

- Model KNN

K-Nearest Neighbors (KNN)

In [10]:
```
#202431160_CLAUDIA
knn_model = Pipeline(steps=[
    ('preprocessing', preprocessor),
    ('model', KNeighborsClassifier(n_neighbors=5, weights='distance'))
])
knn_model.fit(X_train, y_train)
knn_pred = knn_model.predict(X_test)
knn_scores = knn_model.predict_proba(X_test)[:, 1]

knn_result = evaluate_classifier('KNN (k=5)', y_test, knn_pred, knn_scores)
print('Hasil evaluasi KNN:')
display(pd.DataFrame([knn_result]).set_index('Algoritma'))
print(classification_report(y_test, knn_pred, target_names=['Tidak diabetes', 'Diabetes'], zero_division=0))
cm = confusion_matrix(y_test, knn_pred)
plt.imshow(cm, interpolation='nearest')
plt.title('Confusion Matrix – KNN')
plt.colorbar()
plt.xticks([0, 1], ['Prediksi 0', 'Prediksi 1'])
plt.yticks([0, 1], ['Aktual 0', 'Aktual 1'])
for i in range(2):
    for j in range(2):
        plt.text(j, i, str(cm[i, j]), ha='center', va='center')
plt.tight_layout()
plt.show()
```

Membuat pipeline preprocessing dan KNN dengan k=5 serta bobot jarak, melatih model, membuat prediksi, menampilkan metrik, laporan klasifikasi, dan confusion matrix

- Model Linear Regression

Linear Regression

In [11]:
```
# WATERMARK: 202431160 - CLAUDIA SHERLY FEBRIANA DEWI
linear_model = Pipeline(steps=[
    ('preprocessing', preprocessor),
    ('model', LinearRegression())
])
linear_model.fit(X_train, y_train)
linear_scores = linear_model.predict(X_test)
linear_pred = (linear_scores >= 0.5).astype(int)

linear_result = evaluate_classifier('Linear Regression (threshold=0.5)', y_test, linear_pred, linear_scores)
linear_result['RMSE'] = mean_squared_error(y_test, linear_scores) ** 0.5
linear_result['R2'] = r2_score(y_test, linear_scores)
print('Hasil evaluasi Linear Regression:')
display(pd.DataFrame([linear_result]).set_index('Algoritma'))
print(classification_report(y_test, linear_pred, target_names=['Tidak diabetes', 'Diabetes'], zero_division=0))
cm = confusion_matrix(y_test, linear_pred)
plt.imshow(cm, interpolation='nearest')
plt.title('Confusion Matrix – Linear Regression (threshold 0.5)')
plt.colorbar()
plt.xticks([0, 1], ['Prediksi 0', 'Prediksi 1'])
plt.yticks([0, 1], ['Aktual 0', 'Aktual 1'])
for i in range(2):
    for j in range(2):
        plt.text(j, i, str(cm[i, j]), ha='center', va='center')
plt.tight_layout()
plt.show()
```

Melatih Linear Regression pada target 0/1, mengubah skor menjadi kelas dengan ambang 0,5, lalu menghitung metrik klasifikasi serta RMSE dan R^2.

- Perbandingan Model

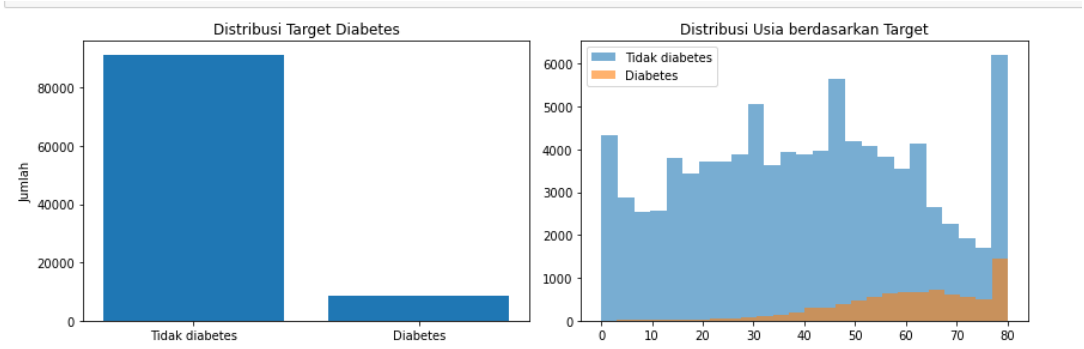
Perbandingan Model

In [13]:
```
#202431160_CLAUDIA
comparison = pd.DataFrame([knn_result, linear_result]).set_index('Algoritma')
display(comparison.round(4))
comparison[['Accuracy', 'Balanced Accuracy', 'Precision', 'Recall', 'F1-score', 'ROC-AUC']].plot(kind='bar', figsize=(12, 5))
plt.title('Perbandingan Kinerja Model')
plt.ylabel('Skor')
plt.ylim(0, 1)
plt.xticks(rotation=15, ha='right')
plt.tight_layout()
plt.show()
```

Menampilkan tabel metrik dan grafik batang untuk membandingkan performa dua model

3.2 Hasil EDA

Dataset berukuran 100.000 baris dan 9 kolom, tidak memiliki nilai kosong, serta memiliki 3.854 baris duplikat. Kelas tidak diabetes adalah 91,5%, sedangkan kelas diabetes 8,5%. Kondisi ini membuat accuracy saja tidak cukup untuk menilai kemampuan model mendeteksi kelas diabetes



3.3 Hasil Model KNN

KNN memperoleh accuracy 95.98%, balanced accuracy 81.40%, precision 85.23%, recall 63.82%, F1-score 72.99%, dan ROC-AUC 0.9019. Confusion matrix menghasilkan TN=18112, FP=188, FN=615, dan TP=1085. Recall kelas diabetes sebesar 63,82% menunjukkan bahwa model menemukan sekitar dua pertiga kasus diabetes pada data uji, tetapi masih melewatkan sebagian kasus positif. Kinerja ini lebih informatif daripada accuracy saja

3.4 Hasil Linear Regression

Setelah skor Linear Regression dikonversi menjadi kelas menggunakan ambang 0,5, diperoleh accuracy 94.09%, balanced accuracy 65.37%, precision 99.05%, recall 30.76%, F1-score 46.95%, dan ROC-AUC 0.9537. Nilai RMSE adalah 0.2245 dan R^2 sebesar 0.3518. Confusion matrix menghasilkan TN=18295, FP=5, FN=1177, dan TP=523.

Linear Regression menghasilkan accuracy tinggi, tetapi recall diabetes hanya 30,76%; model melewatkan banyak kasus positif pada ambang 0,5. Hal ini memperlihatkan dampak ketidakseimbangan kelas dan keterbatasan penggunaan regresi linear untuk target klasifikasi biner.

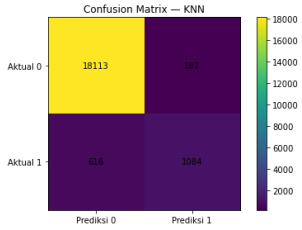
3.5 Perbandingan dan Analisis

Model	Accuracy	Balanced	Precision	Recall	F1-score	ROC-AUC
KNN (k=5)	0.9598	0.8140	0.8523	0.6382	0.7299	0.9019
Linear Regression	0.9409	0.6537	0.9905	0.3076	0.4695	0.9537

Hasil evaluasi KNN:

Algoritma	Accuracy	Balanced Accuracy	Precision	Recall	F1-score	ROC-AUC
KNN (k=5)	0.95985	0.813714	0.852872	0.637647	0.729721	0.902405

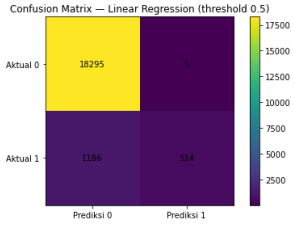
	precision	recall	f1-score	support
Tidak diabetes	0.97	0.99	0.98	18300
Diabetes	0.85	0.64	0.73	1700
accuracy			0.96	20000
macro avg	0.91	0.81	0.85	20000
weighted avg	0.96	0.96	0.96	20000



Hasil evaluasi Linear Regression:

Algoritma	Accuracy	Balanced Accuracy	Precision	Recall	F1-score	ROC-AUC	RMSE	R2
Linear Regression (threshold=0.5)	0.94045	0.65104	0.990366	0.302353	0.463272	0.953259	0.224586	0.351479

	precision	recall	f1-score	support
Tidak diabetes	0.94	1.00	0.97	18300
Diabetes	0.99	0.30	0.46	1700
accuracy			0.94	20000
macro avg	0.96	0.65	0.72	20000
weighted avg	0.94	0.94	0.93	20000



KNN lebih seimbang untuk mendeteksi kelas diabetes pada ambang dan konfigurasi yang diuji: recall dan F1 score lebih tinggi daripada Linear Regression. Linear Regression memiliki ROC-AUC lebih tinggi pada skor kontinu, tetapi hasil klasifikasi pada ambang 0,5 memiliki recall rendah. Perbedaan ini menegaskan bahwa ROC-AUC dan metrik pada satu ambang mengukur aspek yang berbeda. Hasil juga dipengaruhi class imbalance, konfigurasi model, dan data duplikat yang dipertahankan

3.6 Interpretasi Hasil Confusion Matrix

Confusion matrix memberikan rincian kesalahan klasifikasi dari masing-masing algoritma. Pada KNN, terdapat 18.112 true negative dan 1.085 true positive. Model juga menghasilkan 188 false positive serta 615 false negative. Artinya, sebagian besar observasi kelas 0 berhasil dikenali, sementara dari seluruh observasi yang benar-benar termasuk kelas 1, masih terdapat sejumlah kasus yang diprediksi sebagai kelas 0.

Komponen	Keterangan
True Positive (TP)	Data positif yang diprediksi positif
True Negative (TN)	Data negatif yang diprediksi negatif
False Positive (FP)	Data negatif yang diprediksi positif
False Negative (FN)	Data positif yang diprediksi negatif

Tabel tersebut menunjukkan perbedaan kecenderungan kedua model. KNN menghasilkan true positive lebih banyak daripada Linear Regression, yaitu 1.085 dibandingkan 523. KNN juga memiliki false negative lebih sedikit, yaitu 615 dibandingkan 1.177. Hal ini sejalan dengan recall KNN yang lebih tinggi. Sebaliknya, Linear Regression hanya menghasilkan 5 false positive, sehingga prediksi positifnya sangat sedikit tetapi lebih selektif. False negative menjadi perhatian penting dalam konteks dataset kesehatan karena kasus yang sebenarnya berlabel diabetes tetapi diprediksi sebagai bukan diabetes tidak terdeteksi oleh model. Pada KNN, jumlah false negative masih cukup besar dan menunjukkan bahwa model belum menemukan seluruh kasus positif. Pada Linear Regression, jumlah false negative lebih tinggi lagi. Oleh karena itu, kedua model belum dapat dianggap sempurna untuk mendeteksi seluruh observasi positif. False positive juga perlu diperhatikan karena menunjukkan observasi kelas 0 yang keliru diberi label kelas 1. Jumlah false positive Linear Regression yang rendah berkaitan dengan precision yang tinggi. Namun, precision tinggi tersebut tidak boleh ditafsirkan sendirian, sebab model juga menghasilkan recall yang rendah. Penilaian model harus mempertimbangkan keseimbangan antara keberhasilan menemukan kasus positif dan ketepatan prediksi positif.

3.9 Perbandingan Metrik Evaluasi

Perbandingan metrik memperlihatkan bahwa setiap ukuran menilai aspek kinerja yang berbeda. Accuracy KNN sebesar 95,98% lebih tinggi daripada Linear Regression sebesar 94,09%. Selisih ini menunjukkan bahwa pada keseluruhan data uji, proporsi prediksi benar KNN lebih besar. Akan tetapi, karena distribusi kelas tidak seimbang, accuracy belum cukup untuk menyimpulkan bahwa suatu model lebih baik dalam mendeteksi diabetes.

Metrik	KNN	Linear Regression
Accuracy	95,98%	94,09%
Balanced accuracy	81,40%	65,37%
Precision	85,23%	99,05%
Recall	63,82%	30,76%
F1-score	72,99%	46,95%
ROC-AUC	0,9019	0,9537

Balanced accuracy KNN sebesar 81,40% lebih tinggi daripada Linear Regression sebesar 65,37%. Ukuran ini mempertimbangkan kemampuan mengenali kedua kelas, sehingga memberikan gambaran yang lebih seimbang pada data dengan distribusi target tidak merata. F1-score KNN sebesar 72,99% juga lebih tinggi daripada Linear Regression sebesar 46,95%. Hasil tersebut memperlihatkan bahwa pada konfigurasi pengujian ini, KNN memiliki keseimbangan precision dan recall yang lebih baik.

Precision Linear Regression sebesar 99,05% merupakan nilai tertinggi di antara kedua model. Artinya, hampir seluruh observasi yang diprediksi sebagai kelas diabetes oleh Linear Regression memang merupakan kelas positif pada data uji. Namun, recall hanya 30,76%, sehingga model hanya berhasil menemukan sebagian kecil dari keseluruhan kasus positif. Dengan kata lain, model cenderung sangat berhati-hati dalam memberikan prediksi positif

pada ambang 0,5. ROC-AUC Linear Regression sebesar 0,9537 lebih tinggi dibandingkan KNN sebesar 0,9019.

ROC-AUC dihitung dari skor model pada berbagai ambang, sedangkan precision, recall, dan F1-score pada tabel dihitung setelah skor diubah menjadi label menggunakan ambang tertentu. Karena itu, ROC-AUC yang lebih tinggi tidak selalu berarti recall pada ambang 0,5 juga lebih tinggi. Perbedaan tersebut bukan pertentangan, melainkan menunjukkan bahwa metrik mengukur aspek yang berbeda.

Nilai RMSE Linear Regression sebesar 0,2245 dan R^2 sebesar 0,3518 dicatat sebagai ukuran dari sisi regresi. RMSE menggambarkan besarnya kesalahan skor prediksi terhadap target numerik 0 dan 1, sedangkan R^2 menunjukkan variasi target yang dapat dijelaskan model menurut pendekatan regresi. Kedua nilai ini tidak menggantikan metrik klasifikasi karena tujuan akhir perbandingan pada laporan ini juga melibatkan label kelas hasil ambang 0,5.

BAB IV
PENUTUP

4.1 Kesimpulan Teori

Berdasarkan pembahasan teori, dapat disimpulkan bahwa K-Nearest Neighbors (KNN) dan Linear Regression merupakan algoritma dalam pembelajaran mesin yang memiliki prinsip kerja berbeda. KNN melakukan klasifikasi berdasarkan kedekatan jarak antara data yang diuji dengan data latih, sedangkan Linear Regression digunakan untuk memodelkan hubungan antara variabel independen dan variabel dependen dengan membentuk suatu persamaan linear. Kedua algoritma memiliki kelebihan dan keterbatasan masing-masing, sehingga pemilihan algoritma perlu disesuaikan dengan karakteristik dan tujuan pengolahan data.

4.2 Kesimpulan Praktikum

Berdasarkan hasil praktikum menggunakan dataset Diabetes, algoritma KNN memperoleh akurasi sebesar 95,98%, sedangkan Linear Regression memperoleh akurasi sebesar 94,09%. Meskipun Linear Regression menghasilkan nilai ROC-AUC lebih tinggi, yaitu 0,9537, KNN menunjukkan hasil yang lebih baik dalam mengenali data positif dengan nilai recall 63,82% dan F1-score 72,99%. Sementara itu, Linear Regression memiliki recall sebesar 30,76% dan F1-score 46,95%.

Hasil praktikum menunjukkan bahwa KNN lebih baik dalam mendeteksi kelas positif pada dataset yang digunakan. Namun, hasil akurasi kedua algoritma perlu dianalisis bersama metrik evaluasi lainnya karena dataset memiliki distribusi kelas yang tidak seimbang. Dengan demikian, praktikum ini menunjukkan bahwa pemilihan algoritma tidak cukup hanya berdasarkan nilai akurasi, tetapi juga perlu mempertimbangkan precision, recall, F1-score, balanced accuracy, dan ROC-AUC.

DAFTAR PUSTAKA

Azzahrah, D. S. F., & Alamsyah. (2023). Comparison of probabilistic neural network (PNN) and k-nearest neighbor (k-NN) algorithms for diabetes classification. Recursive Journal of Informatics, 1(2), 73–82. https://doi.org/10.15294/c363d161

Haviluddin, Puspitasari, N., Ery Burhandeny, A., Dhiya Awalia Nurulita, A., & Trahutomo, D. (2022). Naïve Bayes and k-nearest neighbor algorithms performance comparison in diabetes mellitus early diagnosis. International Journal of Online and Biomedical Engineering, 18(15), 202–215. https://doi.org/10.3991/ijoe.v18i15.34143

Irfan, M., Dewi, W. U., Nisa, K., & Usman, M. (2023). Implementasi k-nearest neighbor, decision tree dan support vector machine pada data diabetes. Jurnal Mahasiswa Ilmu Komputer, 4(2), 137–150. https://doi.org/10.24127/ilmukomputer.v4i2.4007

Olisah, C. C., Smith, L., & Smith, M. (2022). Diabetes mellitus prediction and diagnosis from a data preprocessing and machine learning perspective. Computer Methods and Programs in Biomedicine, 220, 106773. https://doi.org/10.1016/j.cmpb.2022.106773

Suyanto, S., Meliana, S., Wahyuningrum, T., & Khomsah, S. (2022). A new nearest neighbor-based framework for diabetes detection. Expert Systems with Applications, 199, 116857. https://doi.org/10.1016/j.eswa.2022.116857